UNIVERSIDAD ADOLFO IBÁÑEZ
FACULTAD DE INGENIERÍA Y CIENCIAS

Optimización

2026-2

Profesora: Dora Jiménez

Modelos no lineales

1



Modelos no lineales

Son problemas más generales, en términos de su estructura y características del óptimo, si es que existe.

Las estructuras que hemos visto (lineales) ya no nos permiten encontrar una solución óptima en todos los casos.

Veremos dos famílias de casos:

- Problemas irrestrictos, es decir, no existen restricciones
- Problemas restringidos

Referencias

- Convex Optimization, S. Boyd y L. Vandenberghe
- Nonlinear Programming, D. Bertsekas

Ejemplos de modelos no lineales

2

Problema de Diseño de embalajes – versión 1
Empresa exportadora

- Una empresa exportadora debe enviar cada mes cierta cantidad de producto a sus clientes. El producto es embalado en una caja rectangular. El fondo de la caja es de un material resistente y su base superficial máxima es de $60\ \mathrm{m}^2$. Al mismo tiempo, la altura de la caja no puede exceder los $12\ \mathrm{m}$

- **¿Qué dimensiones debe tener la caja de manera que el volumen sea máximo?**

Parámetros

- Sea $A = 60\ m^2$ la superficie basal máxima que puede tener la caja
- Sea $H = 12\ m$ la altura máxima que puede tener la caja

Variables de decisión

- Sea x_1 el largo que tendrá la caja
- Sea x_2 el ancho que tendrá la caja
- Sea x_3 la altura que tendrá la caja

Restricciones

- La caja no puede tener una superficie basal mayor a la permitida

$$x_1 x_2 \leq A$$

- La caja no puede tener una altura mayor a la permitida

$$x_3 \leq H$$

- El ancho, largo y alto de la caja no pueden ser negativos

$$x_1, x_2, x_3 \geq 0$$

Función Objetivo

- Maximizar el volumen de la caja

$$\text{MAX}_x\ V = x_1 x_2 x_3$$

Modelo

$$\text{MAX}_x\ V = x_1 x_2 x_3$$
$$\text{s. a.}$$
$$x_1 x_2 \leq A$$
$$x_3 \leq H$$
$$x_1, x_2, x_3 \geq 0$$

- Una empresa exportadora debe enviar cada mes un volumen V de producto. La cara frontal, posterior y base de la caja deben usar un material súper resistente, del cual se pueden usar a lo más una superficie de A en cada caja. Al mismo tiempo, el material de las otras dos caras y la tapa debe comprarse a un costo de c por metro cuadrado. Por otro lado, existe un costo de transporte por caja de k. Finalmente, todas las cajas que se construyan deben tener las mismas dimensiones

- **¿Cuántas cajas se deben fabricar y de qué dimensiones para poder transportar el volumen requerido al mínimo costo?**

Parámetros

- Sea A la superficie basal máxima que puede tener la caja
- Sea V la demanda requerida de producto
- Sea c el costo por metro cuadrado del material súper resistente
- Sea k el costo de transportar cada caja

Variables de decisión

- Sea x_1 el largo que tendrán las caja
- Sea x_2 el ancho que tendrán las caja
- Sea x_3 la altura que tendrán las caja
- Sea Y la cantidad de cajas que se fabricarán

Restricciones (1/2)

- Se debe enviar el volumen requerido

$$Yx_1x_2x_3 = V$$

Restricciones (2/2)

- Se debe respetar el límite de uso por caja de material súper resistente

$$x_1x_2 + 2x_1x_3 \leq A$$

- No negatividad

$$x_1, x_2, x_3, Y \geq 0$$

Función Objetivo

- Minimizar el costo de fabricación y transporte

$$MIN_{x,Y}\ C = cYx_1x_2 + 2cYx_1x_3 + kY$$

Modelo

$$MIN_{x,Y}\ C = cYx_1x_2 + 2cYx_1x_3 + kY$$
$$s.a.$$
$$Yx_1x_2x_3 = V$$
$$x_1x_2 + 2x_1x_3 \leq A$$
$$x_1, x_2, x_3, Y \geq 0$$

Una empresa cuenta con N centros de distribución de sus productos y desea instalar una planta de forma que la distancia total hacia los centros sea mínima. El traslado de productos desde la planta a los centros de distribución lo hacen a través de helicópteros por lo que solo interesa la distancia en línea recta de la planta a cada centro. Asumiendo un punto pre-determinado como el punto $(0,0)$ de los ejes coordenados, se determinó la posición de los centros de distribución, siendo (x_i, y_i) la posición del centro de distribución i

¿Dónde se debería ubicar la planta?

Parámetros

- Sea (x_i, y_i) la posición del centro de distribución i, $i = 1..N$

Variables de decisión

- Sea (z_1, z_2) la posición de la planta

Restricciones

- No existen restricciones

Función Objetivo

- Minimizar la distancia total de la planta a los centros de distribución

$$MIN_z D = \sum_{i=1}^{N} \sqrt{(x_i - z_1)^2 + (y_i - z_2)^2}$$

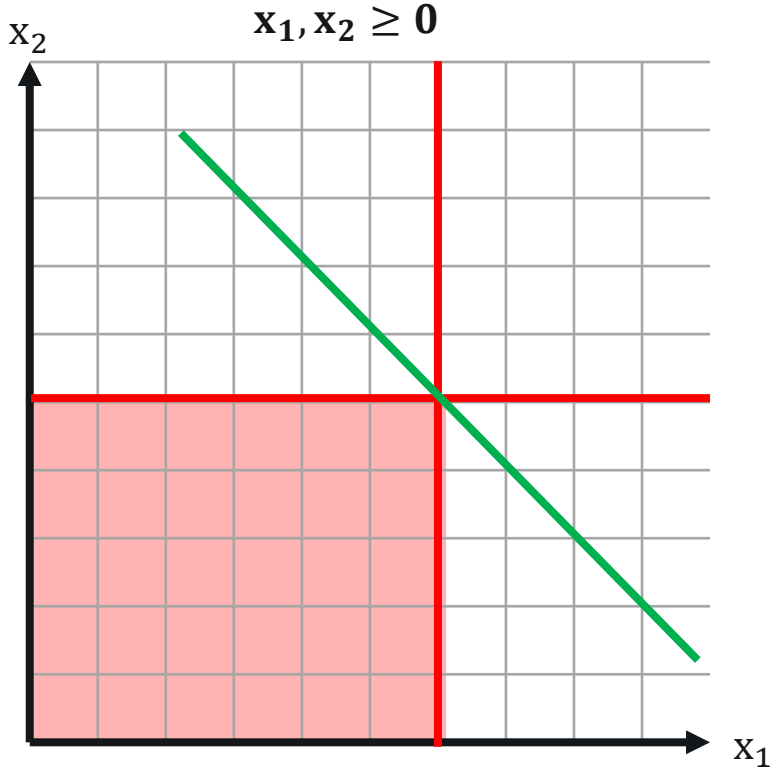
Modelo

$$MIN_z D = \sum_{i=1}^{N} \sqrt{(x_i - z_1)^2 + (y_i - z_2)^2}$$

Hemos resuelto modelos con función objetivo y restricciones lineales, pero ¿qué pasa si relajamos esa condición? (1/2)

Modelo lineal:

$$\mathbf{MAX_x}\ x_1 + x_2$$
$$\text{s. a.}$$
$$x_1 \leq 5$$
$$x_2 \leq 5$$
$$x_1, x_2 \geq 0$$



Modelo no lineal:

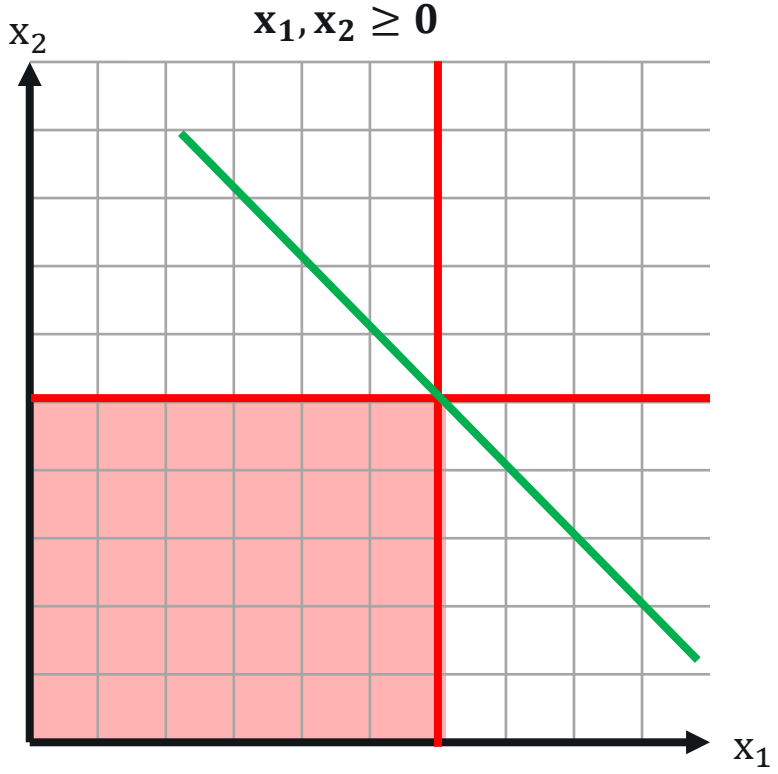
$$\mathbf{MAX_x}\ x_1 + x_2$$
$$\text{s. a.}$$
$$x_1^2 + x_2^2 \leq 25$$
$$x_1, x_2 \geq 0$$



hemos resuelto modelos con función objetivo y restricciones lineales, pero ¿qué pasa si relajamos esa condición? (2/2)

Modelo lineal:

$$\mathbf{MAX_x}\ x_1 + x_2$$
$$\text{s. a.}$$
$$x_1 \leq 5$$
$$x_2 \leq 5$$
$$x_1, x_2 \geq 0$$



Modelo no lineal:

$$\mathbf{MAX_x}\ -(x_1 - 3)^2 - (x_2 - 2)^2$$
$$\text{s. a.}$$
$$x_1 \leq 5$$
$$x_2 \leq 5$$
$$x_1, x_2 \geq 0$$



Al empezar a resolver modelos no lineales, estamos resolviendo modelos más generales que los lineales

- Los métodos que vimos antes ya no nos sirven para resolver estos problemas…
- …por ejemplo, el método simplex busca soluciones en los puntos extremos y como vimos antes en estos problemas…
  - …podemos tener infinitos puntos extremos
  - …el óptimo puede no estar en un punto extremo
- …por lo tanto, no sirve simplex!
- Veremos como resolver (si es que podemos) dos tipos de problemas no lineales…
  - …problemas con restricciones…
  - …y problemas sin restricciones

Convexidad

3

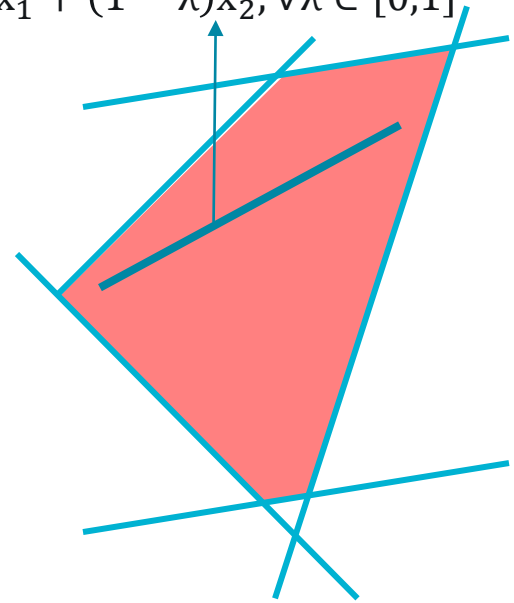
La convexidad de la región factible es clave para determinar los óptimos de un problema no lineal

- Un conjunto D se dice convexo si

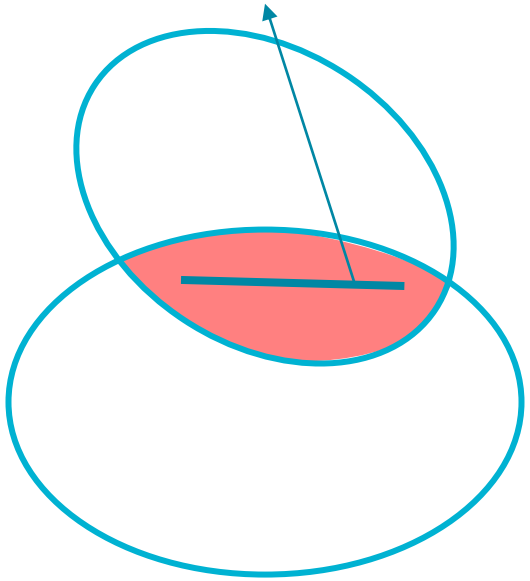
$$\mathrm{x} = \lambda \mathrm{x}_1 + (1-\lambda)\mathrm{x}_2 \in \mathrm{D}, \forall \mathrm{x}_1 . \mathrm{x}_2 \in \mathrm{D}, \forall \lambda \in [0,1]$$

- La intersección de conjuntos convexos es convexo
- La unión de conjuntos convexos no es siempre convexo

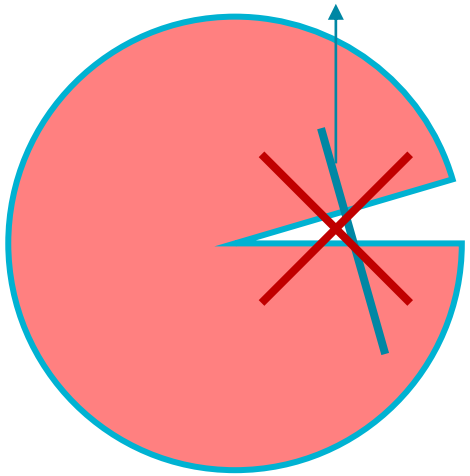
$\lambda \mathrm{x}_1 + (1-\lambda)\mathrm{x}_2, \forall \lambda \in [0,1]$



$\lambda \mathrm{x}_1 + (1-\lambda)\mathrm{x}_2, \forall \lambda \in [0,1]$



$\lambda \mathrm{x}_1 + (1-\lambda)\mathrm{x}_2, \forall \lambda \in [0,1]$

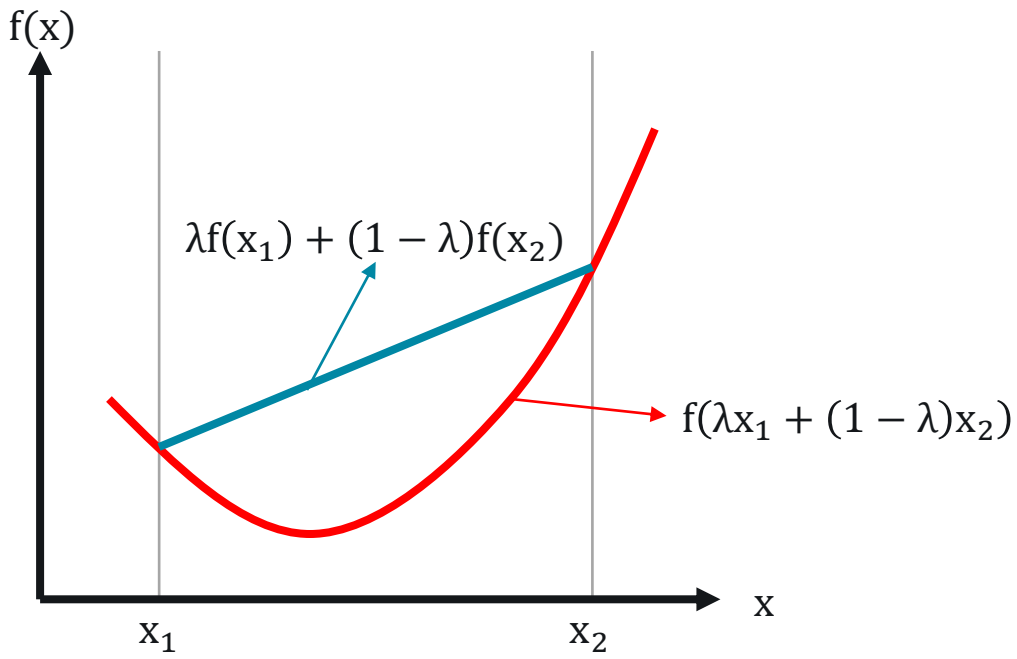


La convexidad de la función objetivo es clave para determinar los óptimos de un problema no lineal

- Sea D un conjunto convexo, entonces diremos que $f(x)$ es convexa en D si…

$$f(\lambda x_1 + (1-\lambda)x_2) \leq \lambda f(x_1) + (1-\lambda)f(x_2), \forall x_1, x_2 \in D, \forall \lambda \in [0,1]$$

- Diremos que $f(x)$ es estrictamente convexa en D si la desigualdad anterior es estricta
- Diremos que $f(x)$ es cóncava si y solo si $-f(x)$ es convexa



Veamos algunos ejemplos de funciones convexas

- Funciones lineales

$$f(x) = a^t x + b$$

- Algunas funciones cuadráticas

$$f(x) = x^t A x + b^t x, A \succcurlyeq 0$$

- Módulos o normas

$$f(x) = \|x\|^p, p \geq 1$$

- Exponenciales y potencias

$$f(x) = e^{ax}$$

Las funciones convexas tienen ciertas propiedades que es importante tener en mente

- Sea $f(x)$ y $g(x)$ dos funciones convexas, entonces:
  - $f(x) + g(x)$ es convexa
  - $\max\big(f(x), g(x)\big)$ es convexa
  - Si $g(x)$ es no decreciente, entonces $g\big(f(x)\big)$ es convexa
- Demostremos que la siguiente función en convexa

$$f(x) = e^{x^2+2|x|}$$

$$\left.\begin{matrix} f_1(x) = x^2 & \text{convexa} \\ f_2(x) = 2|x| & \text{convexa} \end{matrix}\right\} \quad f_3(x) = x^2 + 2|x| \quad \text{convexa}$$

$$f_4(x) = e^x \quad \text{convexa y no decreciente}$$

$$f(x) = f_4(f_3(x)) \quad \text{convexa}$$

Óptimos locales y globales

4

Recordemos la definición de óptimos locales y globales

- Diremos que $x^* \in D$ es máximo global de $f(x)$ en el dominio D si

$$f(x) \leq f(x^*), \forall\, x \in D$$

- Diremos que $x^* \in D$ es mínimo global de $f(x)$ en el dominio D si

$$f(x) \geq f(x^*), \forall\, x \in D$$

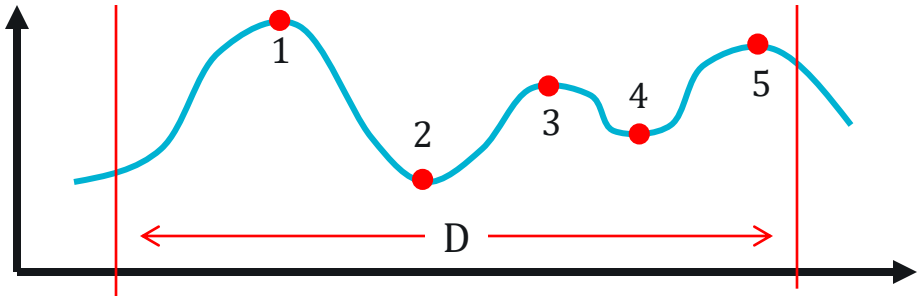
- Diremos que $x^* \in D$ es máximo local de $f(x)$ en el dominio D si

$$\exists \epsilon > 0, f(x) \leq f(x^*), \forall\, x \in B(x^*, \epsilon) \subseteq D$$

- Diremos que $x^* \in D$ es mínimo local de $f(x)$ en el dominio D si

$$\exists \epsilon > 0, f(x) \geq f(x^*), \forall\, x \in B(x^*, \epsilon) \subseteq D$$

- **Teorema de Weierstrass:** Toda función continua $f(x)$ en un dominio D no vacío, cerrado y acotado, tiene un máximo global y un mínimo global en D



1: Máximo Global
2: Mínimo Global
3: Máximo Local
4: Mínimo Local
5: Máximo Local

Funciones convexas y dominios convexos nos permiten definir una condición suficiente para definir un mínimo global (1/6)

- Sea D conjunto convexo y $f(x)$ una función convexa y diferenciable en un punto $x^* \in D$ tal que $\nabla f(x^*) = 0$, entonces x^* es un **mínimo local**

- Sea D conjunto convexo y $f(x)$ una función convexa y diferenciable en D, si existe $x^* \in D$ tal que $\nabla f(x^*) = 0$, entonces x^* es **mínimo global**

  – No siempre existirá $x^* \in D$ tal que $\nabla f(x^*) = 0$, lo que implicaría que el mínimo global podría estar en la frontera y en ese caso x^* puede ser mínimo global con $\nabla f(x^*) \neq 0$…

  – …sin embargo si $D = \mathbb{R}^n$, diremos que el problema de optimización es irrestricto, y x^* es **mínimo global** si y solo si $\nabla f(x^*) = 0$

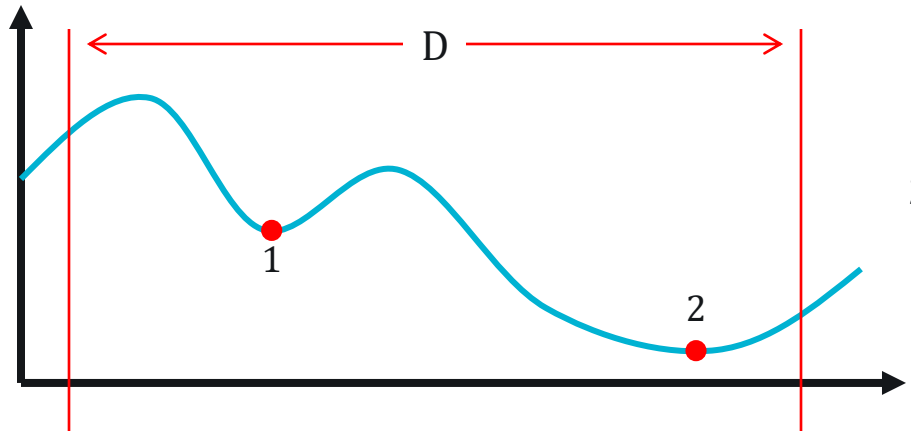
Funciones convexas y dominios convexos nos permiten definir una condición suficiente para definir un mínimo global (2/6)

- Sea D conjunto convexo y $f(x)$ una función convexa y diferenciable en un punto $x^* \in D$ tal que $\nabla f(x^*) = 0$, entonces x^* es un **mínimo local**

- Sea D conjunto convexo y $f(x)$ una función convexa y diferenciable en D, si existe $x^* \in D$ tal que $\nabla f(x^*) = 0$, entonces x^* es **mínimo global**

  – No siempre existirá $x^* \in D$ tal que $\nabla f(x^*) = 0$, lo que implicaría que el mínimo global podría estar en la frontera y en ese caso x^* puede ser mínimo global con $\nabla f(x^*) \neq 0$…

  – …sin embargo si $D = \mathbb{R}^n$, diremos que el problema de optimización es irrestricto, y x^* es **mínimo global** si y solo si $\nabla f(x^*) = 0$



1: Mínimo local
2: Mínimo local (es mínimo global, pero no lo puedo garantizar)

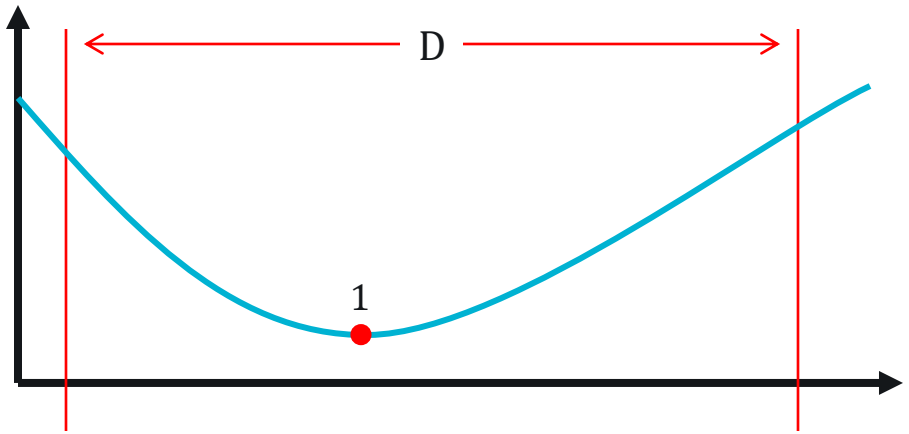
Funciones convexas y dominios convexos nos permiten definir una condición suficiente para definir un mínimo global (3/6)

- Sea D conjunto convexo y $f(x)$ una función convexa y diferenciable en un punto $x^* \in D$ tal que $\nabla f(x^*) = 0$, entonces x^* es un **mínimo local**

- Sea D conjunto convexo y $f(x)$ una función convexa y diferenciable en D, si existe $x^* \in D$ tal que $\nabla f(x^*) = 0$, entonces x^* es **mínimo global**

  – No siempre existirá $x^* \in D$ tal que $\nabla f(x^*) = 0$, lo que implicaría que el mínimo global podría estar en la frontera y en ese caso x^* puede ser mínimo global con $\nabla f(x^*) \neq 0$…

  – …sin embargo si $D = \mathbb{R}^n$, diremos que el problema de optimización es irrestricto, y x^* es **mínimo global** si y solo si $\nabla f(x^*) = 0$



1: Mínimo global y garantizado

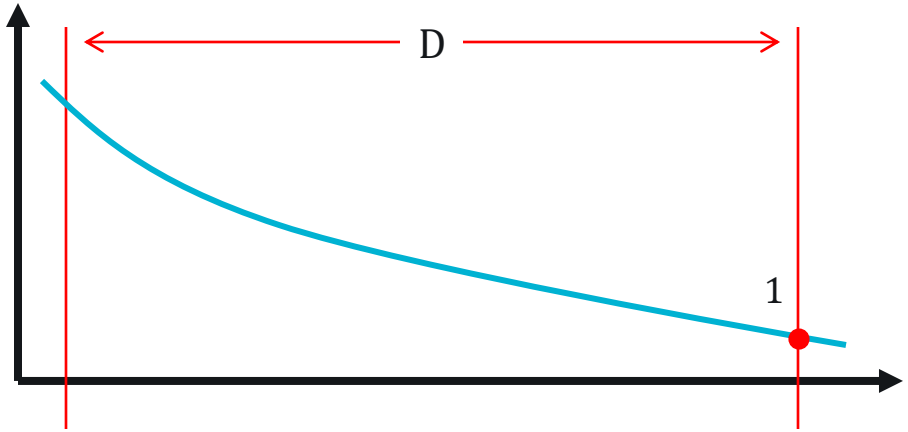
Funciones convexas y dominios convexos nos permiten definir una condición suficiente para definir un mínimo global (4/6)

- Sea D conjunto convexo y $f(x)$ una función convexa y diferenciable en un punto $x^* \in D$ tal que $\nabla f(x^*) = 0$, entonces x^* es un **mínimo local**

- Sea D conjunto convexo y $f(x)$ una función convexa y diferenciable en D, si existe $x^* \in D$ tal que $\nabla f(x^*) = 0$, entonces x^* es **mínimo global**

  – No siempre existirá $x^* \in D$ tal que $\nabla f(x^*) = 0$, lo que implicaría que el mínimo global podría estar en la frontera y en ese caso x^* puede ser mínimo global con $\nabla f(x^*) \neq 0$…

  – …sin embargo si $D = \mathbb{R}^n$, diremos que el problema de optimización es irrestricto, y x^* es **mínimo global** si y solo si $\nabla f(x^*) = 0$



1: Mínimo global y garantizado, pero ¿cómo lo encuentro?

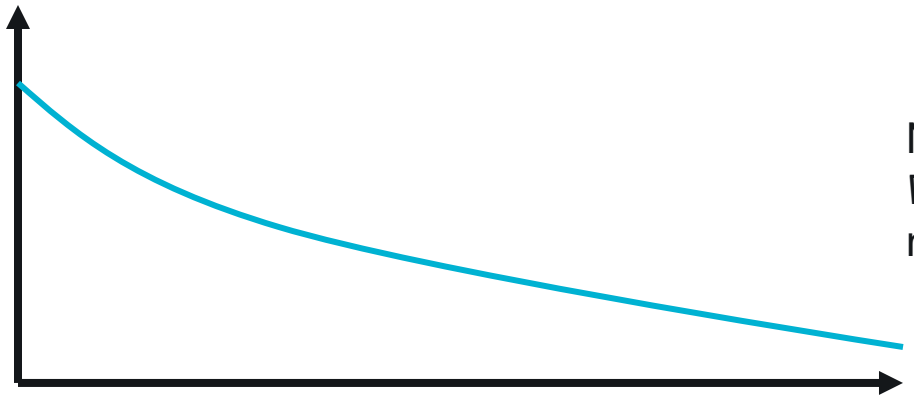
Funciones convexas y dominios convexos nos permiten definir una condición suficiente para definir un mínimo global (5/6)

- Sea D conjunto convexo y $f(x)$ una función convexa y diferenciable en un punto $x^* \in D$ tal que $\nabla f(x^*) = 0$, entonces x^* es un **mínimo local**

- Sea D conjunto convexo y $f(x)$ una función convexa y diferenciable en D, si existe $x^* \in D$ tal que $\nabla f(x^*) = 0$, entonces x^* es **mínimo global**

  – No siempre existirá $x^* \in D$ tal que $\nabla f(x^*) = 0$, lo que implicaría que el mínimo global podría estar en la frontera y en ese caso x^* puede ser mínimo global con $\nabla f(x^*) \neq 0$…

  – …sin embargo si $D = \mathbb{R}^n$, diremos que el problema de optimización es irrestricto, y x^* es **mínimo global** si y solo si $\nabla f(x^*) = 0$



Ningún punto cumple con $\nabla f(x^*) = 0$, por lo que no existe mínimo global

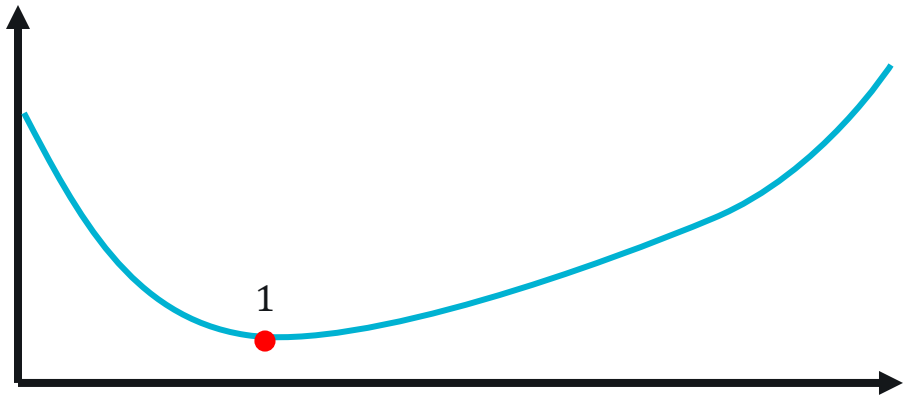
Funciones convexas y dominios convexos nos permiten definir una condición suficiente para definir un mínimo global (6/6)

- Sea D conjunto convexo y $f(x)$ una función convexa y diferenciable en un punto $x^* \in D$ tal que $\nabla f(x^*) = 0$, entonces x^* es un **mínimo local**

- Sea D conjunto convexo y $f(x)$ una función convexa y diferenciable en D, si existe $x^* \in D$ tal que $\nabla f(x^*) = 0$, entonces x^* es **mínimo global**

  – No siempre existirá $x^* \in D$ tal que $\nabla f(x^*) = 0$, lo que implicaría que el mínimo global podría estar en la frontera y en ese caso x^* puede ser mínimo global con $\nabla f(x^*) \neq 0$…

  – …sin embargo si $D = \mathbb{R}^n$, diremos que el problema de optimización es irrestricto, y x^* es **mínimo global** si y solo si $\nabla f(x^*) = 0$



1: Mínimo global y garantizado

Como recordatorio

Gradiente de una función

$$\nabla f(x_1, x_2, \ldots, x_n) = \begin{bmatrix} \frac{\partial f}{\partial x_1}(x_1, x_2, \ldots, x_n) \\ \frac{\partial f}{\partial x_2}(x_1, x_2, \ldots, x_n) \\ \vdots \\ \frac{\partial f}{\partial x_n}(x_1, x_2, \ldots, x_n) \end{bmatrix}$$

Hessiana de una función

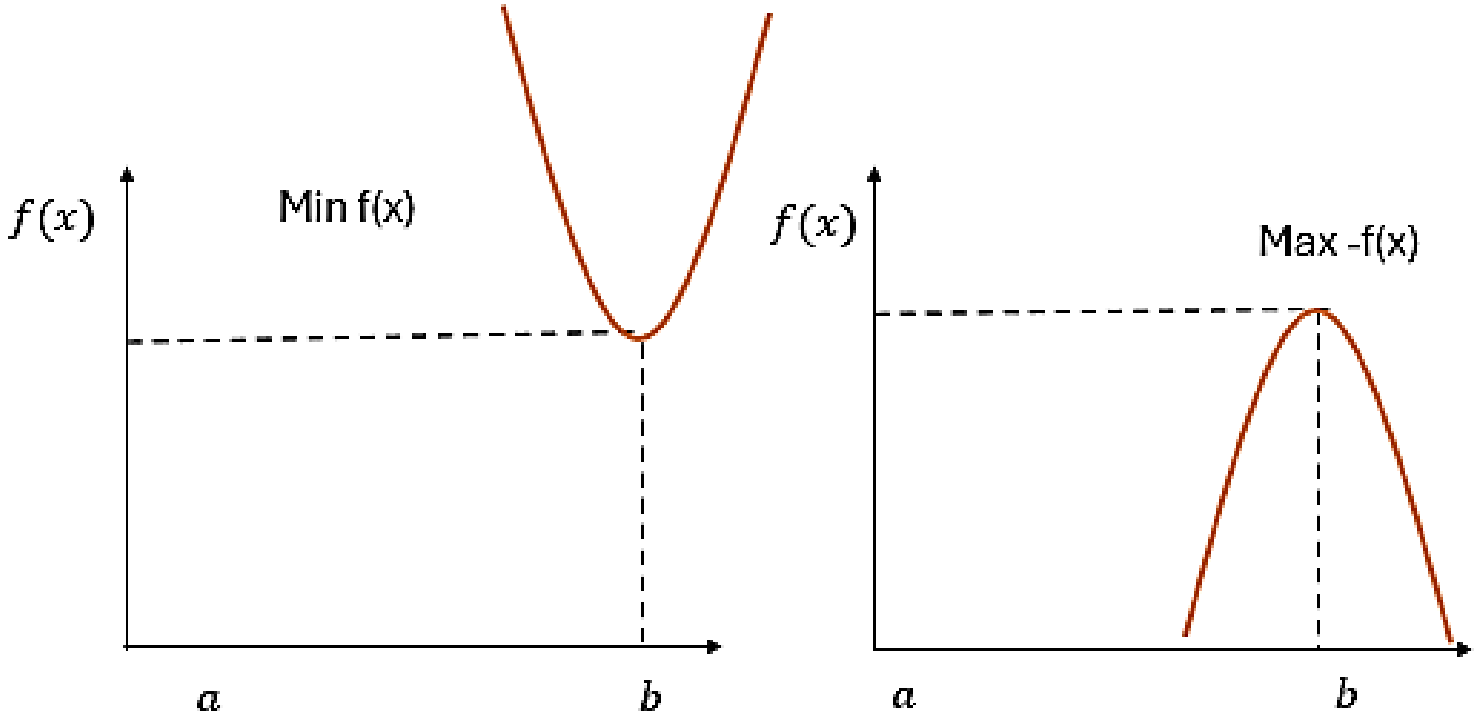
$$H_f = \begin{bmatrix} \frac{\partial^2 f}{\partial x_1^2} & \frac{\partial^2 f}{\partial x_1 \partial x_2} & \cdots & \frac{\partial^2 f}{\partial x_1 \partial x_n} \\ \frac{\partial^2 f}{\partial x_2 \partial x_1} & \frac{\partial^2 f}{\partial x_2^2} & \cdots & \frac{\partial^2 f}{\partial x_2 \partial x_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial^2 f}{\partial x_n \partial x_1} & \frac{\partial^2 f}{\partial x_n \partial x_2} & \cdots & \frac{\partial^2 f}{\partial x_n^2} \end{bmatrix}$$



Optimización no lineal irrestricta

2

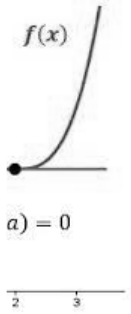
$\text{MAX}\, f(x) = \text{MIN}\ -f(x)$, por lo tanto, para problemas de maximización lo transformamos en problema de minimización y buscamos los mínimos



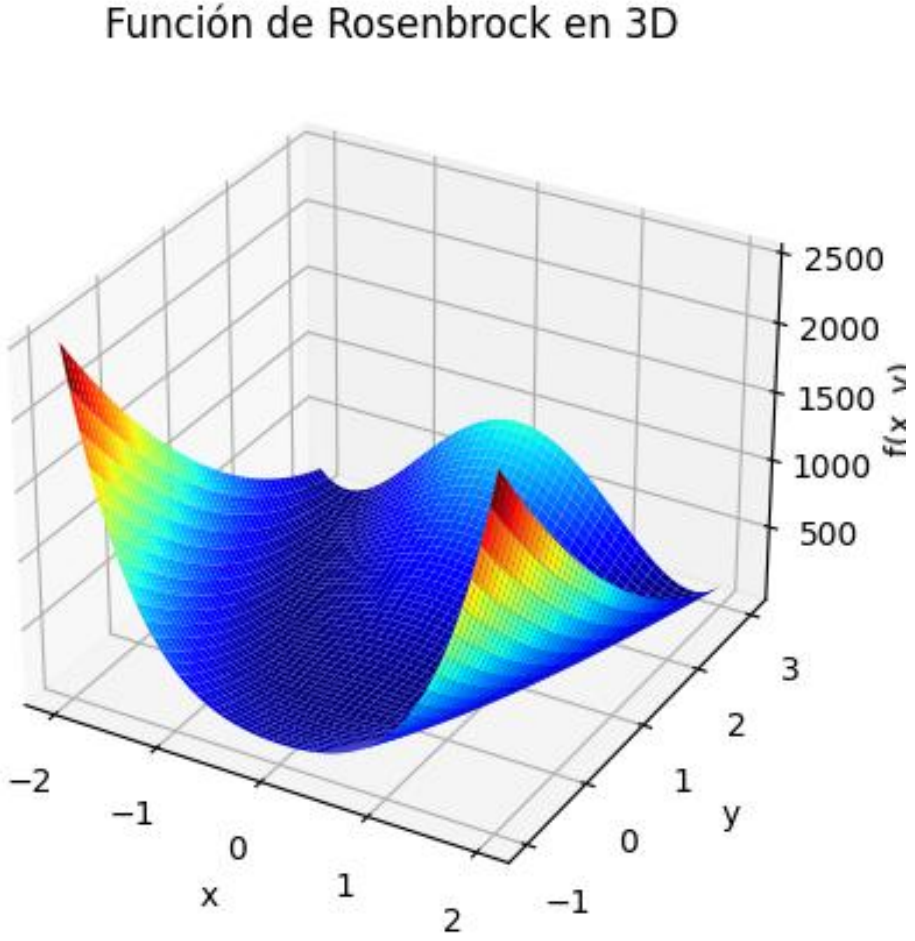
En optimización irrestricta

La optimización irrestricta considera una función $f: R^n \rightarrow R$, la cual se debe determinar puntos que cumplen con el criterio de optimalidad (mínimo o máximo).
Debido a que f puede presentar diversa formas, es necesario considerar condiciones que caractericen potenciales puntos óptimos.

Los punto que podamos obtener pueden ser óptimos globales, locales o puntos silla.



Punto silla



Para las siguientes funciones grafíquelas utilizando Python, y estudie las características de convexidad y/o concavidad.

$$a) f(x,y) = -(x-a)^2 - (y-b)^2$$
$$b) f(x,y) = (x-a)^2 - (y-b)^2$$
$$c) f(x,y) = 3x^2 + 7xy + 5y^2$$
$$d) f(x,y) = 3x^2 + 8xy + 5y^2$$
$$e) f(x,y) = x^2 + y^4$$
$$f) f(x,y) = x^2 - y^4$$
$$g) f(x,y) = (y-x^2)(2x^2 - y)$$

Ver 1. Grafico3D.ipynb

Comentarios importantes

La determinación del gradiente y la Hessiana nos provee información relacionada con la función, y con ello la capacidad de discriminar los tipos de solución que podemos identificar.

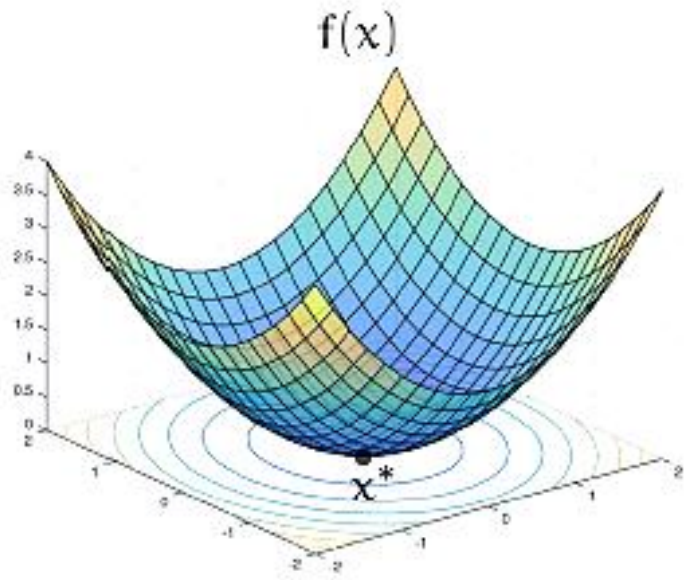
Las propiedades de las funciones y restricciones nos ayudaran a clasificar resultados que obtengamos, ya sea óptimos locales, globales o nada.

Características de la Hessiana

En este caso, desde el punto de vista gráfico, la función es estrictamente convexa.
Esto quiere decir que existe un único mínimo, el cual es global.
Para determinar esto, estudiamos la hessiana de la función f:

$$\nabla f(x,y) = \begin{pmatrix} 2(x-a) \\ 2(y-b) \end{pmatrix}$$

$$H_f = \begin{bmatrix} \frac{\partial^2 f}{\partial x^2} & \frac{\partial^2 f}{\partial x \partial y} \\ \frac{\partial^2 f}{\partial y \partial x} & \frac{\partial^2 f}{\partial y^2} \end{bmatrix} \quad \Rightarrow \quad H_f(x,y) = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix}$$



$$f(x,y) = (x-a)^2 + (y-b)^2$$

Entonces, los determinantes de la hessiana son:
(a) el primero es 2;
(b) el segundo es 4.
Por lo tanto, la matriz hessiana es definida positiva, y con ello la función es estrictamente convexa.
Así, el punto que satisface ∇f(x,y)=0 es un **mínimo global único**.

Resumen de las condiciones de optimalidad

Evaluación de la Hessiana	Condición de la Hessiana	Resultado
En toda la función (sin depender de un punto)	Definida positiva	Mínimo global único
	Semidefinida positiva	Mínimo global
	Ninguno de los anteriores	Punto silla
En un punto específico	Definida positiva	Mínimo local único
	Semidefinida positiva	Mínimo local
	Ninguno de los anteriores	Punto silla

- **Definida positiva**:
Todos los determinantes principales de la hessiana son mayores que cero.
- **Semidefinida positiva**:
Todos los determinantes principales son mayores o iguales que cero, pero no todos estrictamente positivos.

UNIVERSIDAD ADOLFO IBÁÑEZ

FACULTAD DE INGENIERÍA Y CIENCIAS